

三层递进优化： 消费级单卡 GRPO 后训练的系统化极限逼近

Hongyu Chen

DOI: 10.5281/zenodo.21947489 代码与数据:

github.com/ChenHongYu2026/llm-training-on-consumer-amd

摘要

单张消费级 GPU (AMD RX 7900 XTX, 24 GB) 能否有效执行大语言模型的可验证奖励强化学习 (RLVR)? 本文提出一种三层递进优化框架, 在每层逼近该层理论极限后下潜至下一层。(1) **吞吐层** (解耦生成批处理平衡, DGBB): 三参数步时定律与显存模型共同刻画 GRPO 批调度的真实二维可行域; 在硬件墙内, 实测最优 (795.5 tok/s) 达到墙内理论 $\arg\max$ 的 97.6%, 并经受预注册盲预测与证伪朴素外推的探针实验双重检验。(2) **信号率层** (零信号预算重分配, ZSBR): 带诚实上界阶梯的容量理论加解析式 Beta 后验期望评分器, 以零吞吐代价达到 $G=2$ 信号率可达容量的 94%, 三 seed 配对实验 held-out 提升 +7.8 pp (Cohen's $d=7.52$)。 (3) **动力学层** (信号通量最优控制, SFOC): 三池常微分方程模型给出 τ_{net} regime 判据 (relay 速率 μ_0 经四条独立路径交叉验证), 并证明 **调度约束封顶定理**: 在带冷却的调度下, 耗竭主导的动力学结构性不可达。在 GSM8K + Qwen2.5-3B-Instruct 的 20+ 组受控实验中, 准确率从 base 23.2% 提升至 45.6% (单卡 8.5 小时纯 RL 翻倍); 500 道精选题即可达到全池 7473 题的效果 ($15\times$ 数据效率); 且贪心选择在所有实测 regime 下严格最优。首轮全部 13 条预注册可证伪预言收敛于同一自洽图景; 两轮预注册后续实验 (去冷却证伪检验; 跨架构迁移至 Gemma 4 E2B, 其中 DGBB 以 $R^2=0.9983$ 重新拟合) 确认封顶定理并定位需要按基座重新标定的参数。全部负结果如实披露并驱动每一次理论修正。我们公开发布论文、完整训练 prompt 池、全部评估工件以及训练与评估代码。

1 引言

可验证奖励强化学习 (RLVR) 已成为大语言模型推理能力提升的主要驱动力: GRPO (Shao et al., 2024) 这类组相对方法用组内相对优势取代学习的价值函数, 奖励可由规则校验, 并在近年的推理系统中被大规模采用 (Yu et al., 2025)。然而主流实践默认多卡训练集群与数百 GB 的聚合显存, 隐式地把 RLVR 视为只有数据中心规模才负担得起的奢侈品。

我们提出一个刻意刁难的问题: **RLVR 能否在单张消费级 GPU 上有效运行?** 消费级硬件与集群有三个结构性差异: 无张量并行 (整个模型必须装进一张卡的显存)、软件生态更薄 (ROCm




图 1: GSM8K + Qwen2.5-3B-Instruct 上的三层递进优化。每一层的进展都由上一层容量的穷尽所论证：吞吐达到硬件墙内极限的 97.6% 后信号率层才开始；信号率达到 $G=2$ 容量的 94% 后动力学层才开始。held-out 准确率从 23.2% 翻倍至 45.6%。

对 CUDA)、以及串行执行下吞吐与信号质量争夺同一份 GPU 时间。任何肯定回答都必须一层层挣出来，而非假设成立。

我们的答案是肯定的，且附带一套方法论：**三层递进优化**。在每一层，我们 (i) 形式化该层的理论极限，(ii) 测量当前系统距极限多远，(iii) 在该层结构允许的范围内尽量逼近，之后才 (iv) 下潜至下一层——剩余瓶颈所在。这一纪律有具体的回报：当每层都被吃干后再下沉，关于“什么有效”的每个论断都由“为何该层其他方案不可能更有效”的穷尽性论证支撑。图 1 汇总了最终阶梯：GSM8K 的 held-out 准确率从 23.2% 的 base 翻倍至 45.6%，全程纯 RL，一张消费级单卡。

贡献。

1. **吞吐层 (§3)**。三参数步时定律 $T_{step} = a_1 + a_2 B_g + a_3 (B_g / B_b)$ 与分段线性显存模型刻画 GRPO 的两个独立批维度（生成 batch B_g 、反向微批 B_b ）。预注册盲预测、证伪大 B_b 朴素外推的探针实验与双墙显存分析共同确立：实测最优 (795.5 tok/s) 为墙内理论 $\arg\max$ 的 97.6%——批调度维度已被吃干。函数形式以 $R^2=0.9983$ 迁移至第二个模型族。
2. **信号率层 (§4)**。带诚实上界阶梯的容量理论（含“多重入选无法提升组级信号率”的证明）与 Beta 后验期望评分器；评分器的必要性由受控消融证明（点估计失败、后验期望成功）。ZSBR 以零吞吐代价达到 $G=2$ 可达容量的 94%；三 seed 配对 +7.8 pp ($d=7.52$)。

3. **动力学层 (§5)**。刻画训练如何改变 prompt 池通过率分布的三池 ODE 模型； τ_{net} regime 判据 (μ_0 四路径交叉验证)；以及被完整证明的调度约束封顶定理：带冷却贪心调度下耗竭主导动力学结构性不可达。
4. **实践 (§6)**。8.5 小时单卡纯 RL 实现 23.2%→45.6%； $15\times$ 数据效率 (500 题 $\approx$ 全池 7473 题)；首个显式的“何时不需要课程学习”判据。
5. **方法论 (§7)**。预注册-审计协议：首轮 13 条预言全部按时间戳阈值判定，每个负结果都触发有记录的修正，末轮审计实现零缺陷。

行文路线。 第 2 节固定记号并定位相关工作；第 3–5 节按依赖顺序发展三层；第 6 节汇总实践含义；第 7 节描述方法论；第 8–9 节讨论效度威胁与局限。附录含完整预言记分卡、相图数据与 run 清单。

2 背景与相关工作

2.1 GRPO 与信号事件

GRPO 为每题生成 G 条 completion，计算组内相对优势，无需价值网络即可更新策略。设题 q 单条 completion 的奖励分布为 π_q (有限支撑 R)，则该组产生非零优势——信号事件——的概率为

$$P_{sig}(q) = 1 - \sum_{r \in R} \pi_q(r)^G. \quad (1)$$

二值近似 (通过率 p_q) 在 $G=2$ 时退化为

$$P_{sig}(q) \approx 1 - p_q^2 - (1 - p_q)^2 = 2p_q(1 - p_q), \quad (2)$$

在 $p_q=0.5$ (边界题) 处取最大，在稳定做对或稳定做错的题上归零。两个事实使这一量成为全文的组织概念。其一， $G=2$ 时我们在基座模型上测得 `frac_reward_zero_std`=0.75——75% 的生成算力产出零梯度组 (§4)。其二， P_{sig} 只依赖 G 与 π_q 、与生成 batch 无关——该预言经实验显式验证 (附录记分卡 P6)。

2.2 相关工作

Prompt 选择与零方差过滤。 GRESO (Zheng et al., 2025) 在 rollout 之前依据跨 epoch 奖励动力学时序相关性过滤零方差 prompt，并观察到训练中有效 prompt 比例衰减但未建模该衰减。我们的工作从硬件测量出发独立到达同一方向 (§4)；增量在于：决策论意义的评分器及其必要性受控消融、带显式可达界的容量理论、以及 GRESO 所观察衰减的动力学理论。DAPO (Yu et al., 2025) 在 rollout 之后过滤零优势组并过采样补齐；§4.6 给出事前/事后过滤的成本对照。PCL (Gao et al., 2025) 训练价值模型选择中等难度题——对池耗竭短视。RL-ZVP (Le et al., 2025) 保留零方差 prompt 并以熵引导 advantage shaping——修改梯度而非预算分配；我们的负结果划定了其适用

边界（补给主导时投资零信号题为净伤害；§5.7）。SRPO (Li et al., 2026) 将样本路由至自蒸馏，方向正交。

RL 的课程学习与数据选择。 Implicit Curriculum (Huang et al., 2026) 给出均匀训练下 relay 效应的描述性理论——易题持续梯度使稍难题可学——是我们补给项 μ_0 的理论地基；但它不含控制变量与耗竭分析。我们的贡献是规范性对偶：把预算分配建模为池动力学上的最优控制，给出定量 regime 判据与不可能性结果 (§5)。

高效 RL 系统。 RL 训练效率的系统性工作（如生成-训练共调度、rollout 加速）面向集群；消费级单卡的约束集（单卡、无张量并行、24 GB 显存墙）使三层分解——吞吐 $\times$ 信号率 $\times$ 动力学——成为自然的优化结构，因为三种资源都是同一份 GPU 时间。

定位。 据我们所知，这是首个 (a) 把 RLVR 的 prompt 预算分配建模为池动力学上的非短视最优控制，(b) 给出带多路径参数验证的定量 regime 判据 (τ_{net})，(c) 证明现实调度下耗竭的结构不可能定理的工作。写作前检索与实验后新颖性复审均记录于方法学部分 (§7)；复审纠正了一处过度声明 (GRESO 在事前过滤上的优先权)，作为协议产出之一如实记录。

2.3 消费级单卡约束

RX 7900 XTX (RDNA3, gfx1100) 配备 24 GB 显存、960 GB/s 标称带宽 (纯拷贝实测 742 GB/s, 77%)、BF16 GEMM 实测峰值 101.53 TFLOPS。相对训练集群：(i) 无张量并行——全部权重须驻留单卡；(ii) ROCm 相对 CUDA 的生态缺口 (kernel 覆盖、分配器行为)；(iii) 单卡串行执行，吞吐提升与信号质量提升花同一份预算。batch-1 解码受带宽约束，仅达可用带宽的 38% (§3.1)——这正是生成密集型 GRPO 以解码为主导、批调度成为第一杠杆的原因。

3 第 1 层：吞吐——DGBB

3.1 二维解耦

生成密集型 GRPO 的步时由解码主导。标准训练器只暴露一个 batch 旋钮，但 TRL 的语义 (`generation_batch_size = per_device_batch  $\times$  grad_accum`) 揭示了两个独立维度：生成 batch B_g (rollout 相的算术强度) 与反向微批 B_b (梯度相的并行度)，仅受 $B_b \mid B_g$ 约束。解耦生成批处理平衡 (DGBB) 把 (B_g, B_b) 视为两个优化变量。关键是这一解耦不改变任何算法语义——更新规则、样本分布与优化轨迹与标准 GRPO 完全一致；吞吐收益是“免费”的。

步时模型。 每个优化步 = 一次生成相 + B_g/B_b 次反向微批 + 常数开销：

$$T_{step}(B_g, B_b) = T_{gen}(B_g) + \frac{B_g}{B_b} T_{bwd}(B_b) + c. \quad (3)$$

Roofline 论证给出各相一阶结构 $T_{gen}(B) = \alpha_g + \beta_g B$ (固定权重读取 + 每序列边际) 与 $T_{bwd}(b) = \delta + \gamma b$ (每微批开销 + 每序列边际)。代入 (3) 得三参数可辨识形式

$$T_{step} = a_1 + a_2 B_g + a_3 \frac{B_g}{B_b}, \quad a_1 = \alpha_g + c, \quad a_2 = \beta_g + \gamma, \quad a_3 = \delta, \quad (4)$$

其中 a_3 定量刻画 $B_b=1$ 为何低效。吞吐 $TPS = k_{tok} B_g / T_{step}$, k_{tok} 为每序列 token 数 (实测 355.7, ≈ 108 prompt + 247 completion)。

生成相的独立 roofline 验证。 纯解码微基准 (SDPA + static cache, batch $\in \{1, \dots, 64\}$) 拟合 $t_{dec}(B) = 21.63 + 0.413B$ ms/解码步。截距对应每步读取全部 6.17 GB 权重的有效带宽 285 GB/s ——仅为纯拷贝带宽 742 GB/s 的 38%; 这是 batch-1 GEMV 低效的 roofline 表述。模型内部一致性亦成立: $a_2 \approx \beta_g + \gamma$, 其中 $\beta_g \approx 0.413 \text{ ms} \times 247 \text{ 解码步} \approx 0.102 \text{ s/seq}$, 反解 $\gamma \approx 0.256 \text{ s/seq}$ (反向每序列边际), 其隐含的反向 MFU ($\approx 25\%$, 由 $6N\bar{L} \approx 6.6 \text{ TFLOP/序列}$ 推得) 在 LoRA + 梯度检查点的设定下量级合理。

3.2 显存模型与双墙

峰值显存为两相峰值的最大值:

$$M(B_g, B_b) = m_0 + m_g B_g + m_b \max(0, B_b - B_{th}), \quad (5)$$

拟合得 $m_0=6.57 \text{ GB}$ (权重 6.17 GB BF16 加 LoRA、优化器与常驻状态)、 $m_g=0.03625 \text{ GB/序列}$ 、 $m_b=0.46 \text{ GB/序列}$ 、 $B_{th}=4$, 逐点残差 $\leq 0.05 \text{ GB}$ 。由于梯度检查点压缩反向激活, $B_b \leq 4$ 时生成相主导峰值, B_b 从 1 到 4 显存零成本 (实测 8.87 GB 三档完全相同) ——这是“反向 batch 是免费杠杆”的显存侧机理。

随后一次预注册盲预测暴露了模型的边界: 朴素可行性判据预测 gen384 可在 20.49 GB 下运行, 但实测 OOM。对 OOM 日志 (作为数据) 的事后分析给出修正判据 $M_{steady} + M_{spike} + M_{sys} \leq 24 \text{ GB}$: $B_g=384$ 时的一次性分配尖峰 $M_{spike} \approx 3.8 \text{ GB}$ (logits/注意力中间体), 分配器可见范围之外的系统占用 $M_{sys} \approx 1.5\text{--}2 \text{ GB}$ 。修正后的墙落在 (256, 384] token——与实测一致; 对照重跑还显示默认分配器的碎片墙 (损失 3.9 GB) 不同于容量墙, 可被 `expandable_segments` 消除。配套预言 (gen512 $\rightarrow 25.13 \text{ GB} \rightarrow \text{OOM}$) 精确命中。

3.3 拟合质量与朴素外推的证伪

在 7 个可行扫描点上拟合 (4) 得 $a_1=10.829 \text{ s}$ 、 $a_2=0.3579 \text{ s/seq}$ 、 $a_3=0.1702 \text{ s/微批}$, 全部残差在 $\pm 3.3\%$ 内。预注册模型在经验墙内的 argmax 为 pdb8_gen256、预言 843.9 tok/s (较实测最优高 6%); 专用探针实测 $(B_b, B_g)=(8, 256)$ 为 794.3 tok/s——与 pdb4 的 795.5 统计持平 (差 0.15%, 远小于 1–4% 的 run 间变异), 峰值显存亦相同 (15.81 vs. 15.82 GB), 证伪了线性 T_{bwd} 外推: $b>4$ 后的次线性恶化恰好抵消微批数减半的收益, argmax 地形在 $B_b=4$ 之后平坦。加入探针点重拟 (a_3 下修 24%, 最大残差 6.02%) 确认 pdb4_gen256 为真 argmax。表 1 汇总由此得到的利用率层级。

表 1: 批调度维度的利用率层级 (Qwen2.5-3B, $k_{tok}=355.7$, 6ND-MFU 以实测 GEMM 峰值 101.53 TFLOPS 为基准)。实测最优处于墙内 argmax 的测量噪声之内。

层级	描述	tok/s	6ND-MFU
0	实测最优 (pdb4, gen256)	795.5	14.5%
1	墙内理论 argmax	815.3	14.9%
2	无显存墙渐近 ($B_b=4$, $B_g \rightarrow \infty$)	864.8	15.8%
3	微批开销归零 ($B_b \rightarrow \infty$; 实践中被探针证伪)	939.0	17.2%
4	kernel 级改进 (更快反向、量化生成)	>939	—

为什么天花板是结构性的。 分解 $a_2 = \beta_g + \gamma$: 每序列时间 29% 为生成 (带宽受限; MFU 不适用——按带宽利用率计为可达值的 38%), 71% 为反向 (梯度检查点重算、LoRA 分支与 RDNA3 WMMA 效率制约下约 25% MFU)。实测最优之上约 18% 的空间因此位于 kernel 层 (层级 4) 而非批调度层: 调度维度已被吃干。混合的单值 MFU 在此会误导; 分相核算才是方法学要点。

3.4 收敛理论: 吞吐为何换来准确率

GRPO 每步梯度覆盖 B_g 条 completion ($m=B_g/G$ 个 unique prompt), 按 prompt 间独立性有 $\text{Var}[\hat{g}] \propto G/B_g$: gen8→gen128 使方差降 $16\times$ 。三项注册检验确认该机理: (i) 奖励曲线方差比 $9.2\times$ (理论 $16\times$, 同量级; 地板来自非平稳学习漂移与离散奖励支撑); (ii) 最终准确率的 seed 间离散减半 (1.14 vs. 2.25 pp) ——轨迹更确定的预先声明后果; (iii) 等样本裁决实验: gen128×100 步 (34.6%) vs. 等 12800 样本的 gen8×1600 步 (34.4%) ——大 batch 不牺牲单位样本学习效率, 吞吐优势 1:1 转化为收敛墙钟优势 (约 $1/5$ 墙钟)。等步数预算下多 seed 配对增益为 $+3.9$ pp ($d=2.66$), 以样本量为主因、方差下降为副因。

3.5 采用的配置与跨架构复现

gen256 显存临界; 吞吐-显存甜点 gen128 (pdb4, ga32; 745.2 tok/s @ 11.26 GB, $T_{step} \approx 60$ s) 被用于其后全部训练。在第二个基座 (Gemma 4 E2B, 1.6B 文本多模态) 上同一解耦形式以 $R^2=0.9983$ 重新拟合: $T_{step} = 4.40 + 0.431 B_g + 0.174 (B_g/B_b)$ ——函数形式可迁移, 系数随模型而异 (预言 P-C1, ✓)。显存墙移至 ≥ 512 token (16.4 GB, 无 OOM), 对比 Qwen 的 (256, 384], 反映架构特定的显存效率。DGBB 由此从单模型案例升格为可迁移的吞吐定律。

4 第 2 层: 信号率——ZSBR

吞吐吃干后, 下一个杠杆不是更多算力, 而是单位算力的更多信号。 $G=2$ 时基座模型的零标准差组占比 (frac_reward_zero_std) 实测为 0.75——即 75% 的生成组内奖励完全相同, 优势为零、梯度为零。零信号预算重分配 (ZSBR) 在生成之前预测每题的信号概率, 把固定组预算从预测零信号的题上重新分配出去。

表 2: 信号率容量阶梯 ($G=2$)。L4 需要 per-prompt 自适应 G , 固定 G 的训练器未经改造无法表达; 标准训练器下可达阶梯在组级口径止于 L1。

层级	机制	组级上界	覆盖上界	可达
L0	均匀采样	0.25	—	基线
L1	完美选择 (全选 $p \approx 0.5$)	0.50	0.50	是
L2	多重入选 $k \leq 2$	0.50 (不变)	0.75	是
L3	多重入选 $k \leq 3$	0.50 (不变)	0.875	是
L4	per-prompt 自适应 G	$\rightarrow 1$	$\rightarrow 1$	否

4.1 形式化与均匀基线

设 prompt 池 Q ($|Q|=7473$), 每步组预算 $M=B_g/G=64$, 奖励支撑 $\{0, 0.1, 0.9, 1.0\}$ (错 / 仅格式 / 近似 / 对)。精确信号概率为 (1); 二值近似 (2) 在 4 值支撑下是下界 (仅格式分歧的组 $\{0, 0.1\}$ 也产生信号)。均匀采样的系统信号率 $S_0 = \mathbb{E}_{q \sim U}[P_{sig}(q)] = 0.25$ (由实测零标准差占比校准): 64 个组槽位只有 16 个携带梯度。选择目标为

$$\max \bar{S} = \frac{1}{T} \sum_t \frac{1}{M} \sum_{q \in A_t} P_{sig}(q) \quad \text{s.t.} \quad |A_t| = M, \quad (6)$$

其中 A_t 为第 t 步入选题集。

4.2 容量理论: 诚实的上界阶梯

“还剩多少空间”的论断需要显式账本。表 2 记录 $G=2$ 的容量阶梯, 并区分文献中常被混淆的两个口径: 组级信号率 (产生非零优势的组占比, 直接由 $1 - \text{fzs}$ 度量) 与题级覆盖 (该题至少一组产生信号的概率)。

两条声明保证账本诚实。其一, 多重入选无法提升组级信号率: 问题第二组与第一组的 P_{sig} 相同, 额外槽位增加的是被覆盖题数而非产生信号的组占比——组级口径无论 k 多大都封顶于 $L1=0.50$ (此条修正了我们自己预注册中的一处过度声明, 记为记分卡 P5)。其二, L1 可达性依赖经验通过率分布: 要求 $\geq M$ 道可被估计器识别的边界题。我们的反卷积分布 (§5.1) 含 ≈ 3425 道边界题 $\gg M$, 因此上界有效; ZSBR-V1 达到 $S=0.425$, 即 ε 修正后 L1 上界的 94% (预留 $\varepsilon=0.2$ 探索后为 0.45; 理想 0.50 的 85%)。

4.3 估计器: 为何后验期望是必需的

通过率在线估计采用 Beta 先验 + 时间衰减计数, $\hat{p}_q = (\alpha_0 + \gamma^{\Delta t} s_q) / (\alpha_0 + \beta_0 + \gamma^{\Delta t} n_q)$, $\alpha_0 = \beta_0 = 1$, $\gamma = 0.98$ (半衰期 ≈ 34 cycle)。未见题 $\hat{p}=0.5$ 使其最具吸引力——乐观冷启动兼作免费探索, 无需显式 UCB。

受控消融（点估计 vs. 后验期望）。把点估计代入非线性映射 $p \mapsto 2p(1-p)$ 后，未见题 ($\hat{p}=0.5 \Rightarrow \hat{P}_{sig}=0.5$) 与被证实的边界题 ($\hat{p}=0.5 \Rightarrow \hat{P}_{sig}=0.5$) 完全并列；约 5000 道未见题对约 600 道混合题，贪心槽被探索淹没，行为退化为准均匀（实测：fzs=0.708, coverage 0.614, 预注册闸门未过）。修复采用 Beta 后验期望评分， $G=2$ 时有解析式：

$$\mathbb{E}[P_{sig} | D] = \mathbb{E}[2p(1-p) | D] = \frac{2\alpha\beta}{(\alpha+\beta)(\alpha+\beta+1)}, \quad (7)$$

排序为混合 (0.400) > 未见 (0.333) > 一致 (0.300)，且随证据加深（混合见两次：0.4286）。完全相同配置下后验期望评分通过闸门（fzs=0.575）。据我们所知，这一配对失败/成功是“小样本 RLVR 调度中不确定性必须进入评分”的首次受控证明。另一处校准细节：插件估计 $1 - \sum_r \hat{\pi}_r^2$ 携带 $(n-1)/n$ 小样本偏差—— $n=2$ 时为 2 倍——可用标准无偏修正去除。

覆盖与冷却。 纯贪心有两种失效模式：估计器停滞（分布外遗忘）与边界池垄断。 ε 混合保留 εM 槽对池中其余题目均匀采样（保证每题每步至少 $\varepsilon M/|Q|$ 探索概率），冷却 $C=3$ cycle 使近期入选题退出贪心槽。奖励为 4 值支撑，“会作答但算错”的近边界题仍产生部分信号；调度器经 4 值后验追踪之。

4.4 V2 多重入选：水填法及其退化

既然固定 G 训练器中 per-prompt G 不可行，V2 允许一题占用 $k_q \leq k_{max}=3$ 个组槽位（各组独立采样、独立归一化）， $\sum_q k_q = M$ 。线性目标 $\sum k_q P_{sig}(q)$ 会把全部预算压到单题上；正确目标是覆盖

$$v(q, k) = 1 - (1 - P_{sig}(q))^k, \quad \max \sum_q v(q, k_q) \text{ s.t. } \sum k_q = M, 0 \leq k_q \leq 3. \quad (8)$$

边际收益 $\Delta v(q, k) = P_{sig}(q)(1 - P_{sig}(q))^k$ 对 k 严格递减，故 (8) 是可分离凹最大化，贪心水填全局最优。

结果与理论澄清。 V2 实测 fzs=0.561、held-out 40.2%、吞吐 -1.4%——但重复槽位为零。这不是实现失败：边界池 1549 题 $\gg$ 51 个贪心槽时，第二槽边际 $0.40 \times 0.60=0.24$ 恒低于下一道未见题的 ≥ 0.333 ，水填最优解就是不重复；V2 恰如数学所预言地退化为 V1。V2 的适用前提——边界池小于贪心槽位数（小数据集或训练后期）——在后来的 pool-200 regime 得到验证 (§5.6)。

4.5 主结果（三 seed，配对，同轮）

表 3 报告预注册对照。首轮全部六条预言 P1–P6 均在运行前写入时间戳（附录 A）；P1–P4、P6 通过，P5 因预言自身口径混淆而失败（已在 §4.2 记录并更正）。

三个结构性观察：(i) 信号率跨 seed 一致到 0.2 pp——它是算法结构的确定量，与 held-out 准确率的 seed 随机性形成对照；(ii) ZSBR 的 seed 离散 (0.9 pp) 小于 uniform (1.6 pp) ——高信号训练更可复现，与 §3.4 的方差理论一致；(iii) 有效信号组/秒提升 $1.75 \times (0.450 \text{ vs. } 0.257)$ ，coverage 0.224 ——低覆盖与高 held-out 并存是算法的意图（预算集中），而非过拟合。

表 3: ZSBR-V1 对均匀采样（等步数预算 100 步、等吞吐）。held-out: GSM8K test[:500], batch 32, 三 seed 按 seed 配对。fzs: 零标准差组占比, 训练后半程。

臂	Seed 42	Seed 123	Seed 7	均值 $\pm$ 标准差
Uniform held-out	31.0%	34.0%	33.2%	32.7% $\pm$ 1.6
ZSBR-V1 held-out	39.6%	40.6%	41.4%	40.5% $\pm$ 0.9
配对差	+8.6	+6.6	+8.2	+7.8 pp, $d=7.52$
fzs (后半程)	0.575	0.573	0.575	一致到 0.2 pp
T_{step} 变化		-2.6% (零吞吐代价)		

4.6 与事后过滤 (DAPO) 的对照

DAPO 式动态采样全部生成、丢弃零优势组、过采样补齐至 M 个有效组；其每有效组生成成本为 $1/S$ ，且步时与显存峰值可变。ZSBR 的每有效组成本同为 $1/S_{ZSBR}$ ，但步时与显存 恒定 (与吞吐层的保证正交)。在达到的 $S_{ZSBR}=0.425$ 下，匹配 uniform 的有效组产出需 DAPO 多花 $\approx 1.66\times$ 生成墙钟；ZSBR 零墙钟代价。两者可组合（再过滤 ZSBR 漏选的零信号组），留作未来工作。

4.7 长训练：45.6% 里程碑

不加修改地把 ZSBR-V1 延长至 500 步 (8.5 小时, 单卡), held-out 从 40.6% (100 步 regime) 升至 **45.6%** (228/500; step 250 中间检查点 40.6%, 单调、无过拟签名; 最终 KL 0.0070, reward 0.51)。这是 base 23.2% 的纯 RL 翻倍, 至今仍是项目最高结果。延长期内信号率不衰减 (fzs 三段 0.592/0.554/0.541, 即零标准差占比下降、信号上升) ——这一观察开启了动力学层。

4.8 跨架构迁移

Gemma 4 E2B 上 $S_0=0.400$ (Qwen 为 0.25): 基座本就解对更多题, 压缩了重分配的提升空间 (S_0 压缩假说, 预注册)。100 步迁移测试实测 uniform 29.27% vs. ZSBR 28.87% (-0.40 pp, $t=-0.53$; 预言 P-C2 $\times$), 但方差下降 $4\times$ (ZSBR $\sigma=0.3$ pp vs. uniform 1.2 pp): 信号已充裕时, 重分配稳定均值而非提升均值。窗口也可能过短 (Qwen 的 $+7.8$ pp 需要 500 步)。两条保留均预注册声明。

5 第 3 层：动力学——SFOC 相图

第 1-2 层把 prompt 池视为静态。但训练改变模型, 模型改变池: 通过率上升使题目从难池 (D) 经边界池 (M) 迁移到已会池 (S)。选择因此同时是奖励的来源与状态的 驱动——这是控制问题, 不是静态背包。信号通量最优控制 (SFOC) 把这一点显式化, 并追问: 池会耗竭吗? 投资 (把预算花在难题上促其转化) 是否有回报?

表 4: 池构成: 观测标签 ($n=2$) vs. Beta-binomial EM 反卷积 ($n \approx 6$, 三 seed 合并)。

池	观测	真实 (反卷积)
D (难)	50.5%	40.6%
M (边界)	24.2%	45.8%
S (已会)	25.3%	13.6%

5.1 两层状态模型与观测问题

设 $p_q(t)$ 为题 q 在时刻 t 的真实单条通过率, $\rho(p, t)$ 为种群密度。按 $D=[0, \delta)$ 、 $M=[\delta, 1-\delta]$ 、 $S=(1-\delta, 1]$ ($\delta=0.15$) 粗化为三池。系统信号率 $S(t) = \int 2p(1-p)\rho(p, t) dp$ ($G=2$)。

调度器使用的池标签是观测而非真相: 一次入选产生 $G=2$ 条二项观测, 混淆结构

$$P(\text{混合} | p) = 2p(1-p), \quad P(\text{全对} | p) = p^2, \quad P(\text{全错} | p) = (1-p)^2. \quad (9)$$

真 $p=0.5$ 的题只有 50% 概率被观测为“混合”。对三 seed 合并 uniform 日志 (7454 题, 每题 ≈ 6 条观测) 做 Beta-binomial EM 反卷积, 还原真实池构成 (表 4): 真实边界池近乎观测值的两倍 (45.8% vs. 24.2%), 因为 $n=2$ 的二项噪声把一半边界题误标为一致。交叉自洽检验: $S_{true}(\rho)=0.2406$ 预测 $fzs=0.759$, 实测 0.7405。据我们所知, 这是首次定量刻画小 G 观测噪声向课程式调度器隐藏了多少信息。

5.2 三池 ODE 模型与衰减定律

以 cycle 为时间单位, 池占比 $D+M+S=1$, 控制变量 (a_M, a_D) (每 cycle 组预算 $M_b=64$ 的分配比例):

$$\frac{dM}{dt} = \underbrace{\lambda_{DM}(a_D) D}_{\text{relay 补给}} - \underbrace{\lambda_{MS}(a_M) M}_{\text{收割耗竭}}, \quad \begin{cases} \lambda_{MS} = \mu_h \frac{a_M M_b}{|M|}, \\ \lambda_{DM} = \mu_0 + \mu_i \frac{a_D M_b}{|D|}, \end{cases} \quad (10)$$

约束 $a_M + a_D + \varepsilon = 1$ 。收割以人均预算成比例的速率把边界题移入已会池; 补给含自然 *relay* 项 μ_0 (Implicit Curriculum 效应: 其他题上的泛化使难题变为边界题) 与投资项 μ_i 。信号率近似 $S(t) \approx s_M M(t) + s_\varepsilon$ ($s_M \approx 0.45$)。

命题 1 (衰减定律). 短视贪心选择 ($a_D \equiv 0$ ——ZSBR/GRESO/PCL 的共同形式) 下, 边界池满足

$$M(t) = M_0 e^{-t/\tau} + \frac{\mu_0 \bar{D}}{\lambda_{MS}} \left(1 - e^{-t/\tau}\right), \quad \tau = \frac{|M|}{\mu_h M_b a_M}. \quad (11)$$

若 $\mu_0 \bar{D} \ll \lambda_{MS} M_0$, 池指数耗竭 (fzs 回升); 若 *relay* 补给与收割平衡, $M(t)$ 平台化于 $M_\infty = \mu_0 \bar{D} / \lambda_{MS}$ 。两种结局是同一模型的预言; *regime* 由测量决定。

证明. 固定 $(\bar{D}, a_M)$ 下关于 M 的线性常微分方程; 标准积分因子法即得 (11), 令 $dM/dt = 0$ 得平衡点 $M_\infty = \mu_0 \bar{D} / \lambda_{MS}$ 。□

表 5: relay 速率 μ_0 (每深层 D 题每 cycle 的转化数) 的四条独立估计。路径 3–4 依赖平台形态, 路径 1–2 依赖轨迹统计。区间 $[0.002, 0.008]$ 驱动全部相图结论。

路径	方法	$\hat{\mu}_0$
1	fzs 斜率反演 (全池)	0.002
2	平台反推, pool 500	0.0053
3	分层深层重逢, bootstrap CI $[0.0066, 0.0086]$	0.0076
4	平台反推, pool 200	0.0081

三 seed 日志标定 $\mu_h=0.0268$ 次转化/组观测 (seed 间一致于 0.025–0.029), 故 $\tau \approx 2500$ cycle $\gg 500$: 每 cycle 仅约 1.4 道边界题被收割学会, 500 步窗口看不到衰减。这一实验前标定触发了注册的诚实条款: 衰减预言在运行前即被宣布为 窗口内不可判定, 而非事后强行判定 (记分卡 F-a)。

5.3 收割-投资权衡的最优控制

非短视问题最大化累计信号通量 $\int_0^T S(t) dt$, 约束 (10)。哈密顿量 $H = s_M M + \varphi_M \dot{M} + \varphi_D \dot{D}$ 对控制线性, 最优策略为 bang-bang, 开关函数比较边际通量: 收割的即时信号减耗竭代价 ($\nu_M = s_M(\cdot) - \varphi_M \mu_h(\cdot)$) 对投资的延迟信号 ($\nu_D = \varphi_D \mu_i(\cdot)$)。终端条件 $\varphi_M(T)=0$ 给出 “训练末期纯收割、 T 大时早期存在先投后收弧” 的结构预言。固定投资比例 ι (SFC 实现, 默认 $\iota=0.25$; $\iota=0$ 严格退化回 ZSBR-V1) 是该 bang-bang 结构的实用松弛。

相应的短视次优性 gap 满足 $\text{gap}(T) = \int (S_{\text{opt}} - S_{\text{greedy}}) dt \approx 0$ ($T \ll \tau$) 并随 T/τ 单调增长。注意这带来的自治义务: 在我们标定的 regime ($\tau \approx 2500 \gg T=500$) 下, 理论在运行 SFC 之前就预言了自己的投资算法不会有增益。

5.4 τ_{net} 判据与 μ_0 的四路径验证

首轮小池实验暴露了原判据的缺陷: pool-500 出现完美 fzs 平台, 而不含补给项的时标 $\tau_{500} \approx 135$ 预测可见耗竭。错误在于忽略补给项; 修正判据为

$$\tau_{\text{net}} = \frac{|M|}{\mu_h \cdot \text{slots} - \mu_0 |D|}, \quad (12)$$

分母 ≤ 0 即补给主导 (永不耗竭)。 μ_0 是潜变量; 我们以四条独立路径估计之 (表 5): fzs 斜率反演 (0.002)、pool-500 平台反推 (0.0053)、深层全错 cell 分层重逢 + bootstrap CI (0.0076, $[0.0066, 0.0086]$, 2100 事件, 纯零 cell 保证 “未训练” 区间零梯度)、pool-200 平台反推 (0.0081)。跨路径的上漂与 λ 时变一致 (训练中模型增强), 如实记录。工作区间 $\mu_0 \in [0.002, 0.008]$; 动力学形态成为同一参数的第三、第四条验证路径。

5.5 调度约束封顶定理

三个实测 regime 点 (§5.6) 共享同一结构：无论名义 τ 如何，无一耗竭。这不是 GSM8K 的偶然，而是调度器带来的必然。

假设 1. 贪心调度器带冷却 $C \geq 1$ ，每 cycle 从大小为 N 的固定数据集无放回抽取 M_b 组；第 t cycle 入选的题在 $t+1, \dots, t+C$ cycle 退出贪心槽。收割按单次观测速率 μ_h 转化边界题；relay 以聚合速率 $\mu_0|D|$ 补给边界题。

定理 2 (调度约束封顶). 在假设 1 下，每 cycle 的有效收割有上界

$$H_{eff} \leq \mu_h \cdot \frac{|M|}{N} \cdot M_b, \quad (13)$$

且当 $N \rightarrow C \cdot M_b$ 时，收割-补给比收敛于与绝对池大小无关的池构成常数：系统无论名义 τ 如何预测都会自调节至平衡。

证明. 冷却强制数据集上的轮转周期 $\geq C+1$ ，故任何题每 $C+1$ cycle 至多收割一次。每 cycle 触达的不同题数期望为 $\min(M_b, N/(C+1))$ ；当 $N \leq (C+1)M_b$ (小池 regime) 调度器必然轮转全池，触达题中位于 M 的比例期望为 $|M|/N$ 。因此每 cycle 可用于收割的边界观测数 $\leq (|M|/N) M_b$ ，乘以单次观测转化率 μ_h 即得 (13)。同时 relay 补给 $\mu_0|D|$ 亦随池构成缩放：记 $|D| = \rho_D N$ 、 $|M| = \rho_M N$ ，则

$$\frac{H_{eff}}{\mu_0|D|} \leq \frac{\mu_h \rho_M M_b}{\mu_0 \rho_D N},$$

而在轮转饱和 ($N \leq (C+1)M_b$) 下该比对 N 的依赖被收缩的轮转窗口抵消： N 减半同时以相同比例缩小补给质量与每 cycle 收割上限，因为轮转按固定比例触达各池。故该比收敛于 $\mu_h \rho_M / \mu_0 \rho_D$ 乘以调度常数——只依赖构成的量。耗竭要求该比持续大于 1；只要 $\mu_0 \rho_D \gtrsim \mu_h \rho_M M_b / N$ 即被封顶阻止，而实测构成在三个 regime 均满足之 (§5.6)。□

推论 3 (耗竭的结构不可达). 固定数据集 + 带冷却贪心调度下，“选择自由度充分” ($N \gg C \cdot M_b$) 与“补给弱” ($\mu_0|D|$ 小) 结构性互斥——两者随 N 同向变化。耗竭主导动力学因此结构性不可达：系统恒处补给主导或平衡态。

证明. 选择自由度要求 N 大；但 $\mu_0|D| = \mu_0 \rho_D N$ 在固定构成下随 N 线性增长，大 N 同时增强补给。反之小 N 削弱补给但激活定理 2 的轮转封顶，以相同收缩尺度封顶收割。任何 N 都无法同时满足两条件。□

该结果解释了本来看似矛盾的跨论文差异：GRESO (Zheng et al., 2025) 观察到有效比例衰减是因为其运行无冷却、多 epoch 调度 (收割不封顶)，而我们的冷却轮转、亚 epoch 运行全部观察到平台。它也给出“无需课程学习”的首个充分条件 (§6)。

表 6: 三个实测 regime 点的相图数据 ($\mu_0 \in [0.002, 0.008]$; 收割速率 $\mu_h \cdot \text{slots} = 1.37$ 题/cycle)。

Regime	池	$ D $	$ M $	供给 $\mu_0 D $	投资效应
补给主导	7473	3034	3423	$[6.1, 24.3] \gg 1.37$	-6.4 pp ($z=2.05$)
平衡带	500	260	186	$[0.52, 2.1] \approx 1.37$	-6.6 pp ($p<0.001$)
轮转平衡	200	89	84	$[0.18, 0.71] \ll 1.37$	-0.8 pp (不显著)

5.6 实测 regime 点与直接证伪检验

表 6 给出三个实测 regime 点 (相图见图 2a): 全池 7473 (补给主导, fzs 下降)、pool 500 (平衡带, 0.57 完美平台)、pool 200 (轮转自平衡, 第 5 步起 0.73 平台)。pool 100/150 被运行前闸门筛除: 该尺寸下贪心槽饥饿 (τ_{net} 为负且调度余量 < 51), V1 将与 uniform 混淆——NO-GO 在运行前声明。

直接证伪检验: 去冷却。 定理 2 给出锋利的预注册预言: 移除冷却应解锁耗竭 (P-A1)。pool 500 (平衡 regime) 检验确认封顶: 两臂均出现末段 fzs 回升 (无冷却 +4.1 pp vs. 冷却 +5.0 pp; 净差 -0.9 pp), held-out 等价 (+0.6 pp, 位于预注册等价带内)——定理管辖处封顶机制成立。pool 200 移除冷却 打破平台: fzs 从冷却组 0.73 降至 0.59 平台 (-15 pp), 恰在 τ_{net} 最短处解锁耗竭; held-out 反而提升 (41.4% vs. 37.6%, +3.8 pp, 单 seed)。去冷却效应因此依赖池大小: 定理管辖平衡 regime, 而贴近耗竭边界的小池呈现质性不同的动力学——且解锁的耗竭在此并不损害泛化, 修正了“耗竭即伤害”的常见直觉。

5.7 投资闭环: 一条剂量响应负结果

SFC 投资机制在全部三个 regime 点以同轮同卡同口径链式检验。累计信号通量 $\Delta(\text{SFC-V1})$: $-17\% \rightarrow -10.5\% \rightarrow +4.5\%$, held-out 效应 $-6.4 \rightarrow -6.6 \rightarrow -0.8$ pp (图 2b): 一条单调剂量响应——投资伤害随选择自由度塌缩而衰减。pool-200 点是投资惰性化 (候选枯竭: invest slots 2.4/16, 仅 177 件结案), 并非正回报。审计给出的机理分解: (i) 零观测通过的投资组产出 $\{0, 0\}$ 奖励——零优势、零梯度、纯预算消耗 (全池 11.7% 预算); (ii) 补给主导 regime 下转化不具增量性: relay μ_0 本来就会免费转化这些题, 花预算催化必然发生的转化是无补偿的机会成本; (iii) 转化管道本身真实存在——通量恒定 2.33 题/cycle ($R^2=0.9957$)、排序单调 (低预测箱 6% $\rightarrow$ 高箱 86%)——但全池校准高估 1.54 $\times$, 且误差依赖观测密度: pool 200 (平均 72.8 次先验观测 vs. 4.5) 校准恢复 (误差 2.8 pp)。正确模型是“校准误差为观测数的函数”而非常数修正; 我们的首个归因 (rollout 相关性) 被直接测量证伪 ($\rho \approx 0$) 后替换——这条审计链我们照实报告, 因为它正是协议按设计运作的证据。

$G=2$ 与现实调度约束下, 贪心选择在所有实测 regime 严格最优: 三个 regime 点无一投资正回报, 两点显著伤害。




图 2: (a) 供给-收割平面上的三个实测 regime 点；投资伤害随供给/收割比下降而衰减。(b) 单调剂量响应：投资伤害随选择自由度塌缩而衰减（ $-17\% \rightarrow -10.5\% \rightarrow +4.5\%$ 信号通量；held-out $-6.4 \rightarrow -6.6 \rightarrow -0.8$ pp）。

表 7: 里程碑账本（GSM8K test[:500], batch 32; Qwen2.5-3B-Instruct）。

阶段	配置	论证	Held-out
Base	不训练	—	23.2%
+ 吞吐	DGBB gen128, uniform, 100 步	墙内 argmax 的 97.6%	33.3%±1.1
+ 信号	ZSBR-V1, 100 步, 3 seed	$G=2$ 容量的 94%	40.5%±0.9
+ 长训练	ZSBR-V1, 500 步	补给主导, 无耗竭	45.6%

5.8 τ_{net} 的跨架构迁移 (P-C3)

Gemma 4 E2B 上两次 500 步 ZSBR 检验可移植性。Pool 7473: fzs 0.617→0.589 (-2.8 pp)——补给主导平台直接迁移。Pool 500: fzs 0.748→0.728 (-2.1 pp), 不是预测的耗竭下降: E2B 的临界池大小在 500 之下 (Qwen 为 200–500), 与其更高基线信号一致。预注册判定: 判据形式可迁移、参数需重标定——两确认两证伪共同定位了新基座必须重测的参数 (信号充裕度、临界池大小)。

6 关键发现与实践含义

里程碑账本。 表 7 汇总准确率轨迹与每层的论证。

何时不需要课程学习。 结合 (12) 与定理 2: 若数据集以带冷却贪心调度训练, 且 $\mu_0|D| \geq \mu_h \cdot \text{slots}$ (或池足够小使轮转封顶生效), 则信号率平台或上升 (无耗竭), 任何投资都是有损无补的机会成




图 3: 信号率容量阶梯 ($G=2$)。ZSBR-V1 达到 ϵ 修正 L1 选择上界的 94%；L4 (per-prompt 自适应 G) 未经训练器改造不可达；多重入选 (L2/L3) 提升覆盖但不提升组级信号率 (表 2)。

本，纯贪心最优。两个标量 (μ_0 来自 fzs 斜率、 μ_h 来自重逢转化频率) 都是训练日志的免费副产品。这是首个同类适用性判据；此前的选择方法隐式假设了相反的 regime。

数据效率。 Pool-500 ZSBR-V1 达 45.4%，对全池 7473 的 45.6%——6.7% 的数据换取相同结果 (15× 数据效率)；pool-200 (37.4%，−8 pp，无病理签名、reward 仍在爬升) 把无损下限定位在 (200, 500]，归因知识覆盖不足而非耗竭伤害 (混淆按预注册条款写死)。

负结果即正证据。 首轮 13 条预注册预言 (F: 6, G: 3, H: 4) 12 条失败或不可判定——但每条失败都收敛于同一图景：补给主导、投资不必要、贪心足够。一个能预言自己算法失败 (SFC 标定后预言无增益，实测 −6.4 pp) 与自身动机现象结构性不可达 (耗竭) 的理论，展示的是预测内容而非曲线拟合。

7 方法论：预注册与审计协议

六原则，经三轮审计打磨：(1) 任何理论承诺之前强制先行检索 + 书面新颖性声明；(2) 时间戳预注册可证伪预言，带数值阈值，运行前落盘；(3) 诚实条款——“不可判定”在标定窗口无法观测预测效应时是合法判定 (F-a 即行使此条)；(4) 同轮、同卡、同口径对照 (ROC_m 同 seed 重跑因反向原子操作非确定性分叉约 3 pp，故全部对照均同轮配对)；(5) 实验后全量原始数据复算 + 三视角代码评审；(6) 测量先于修正 (rollout 相关性假说被直接测量证伪后才替换归因)。

度量。 全部 fzs 数字使用预注册分段拟合口径：前 2/3 vs. 后 1/3 轨迹；回升 = 末段均值减轨迹最小值 (pp)。从原始 reward_log 复算与报告值吻合于 ± 0.4 pp 内。评估自 pool-500 轮起落盘逐题正确向量，McNemar 配对检验可用 (SFC 伤害 $\chi^2=12.64$, $p<0.001$ ；pool 200 处 $\chi^2=0.18$, 不显著)。

审计轨迹。 E-F 轮：1 处推翻判定 + 5 处偏差发现并修复 (统计量替换、选择性报告、分层键语义漂移)。E-G 轮：2 Critical + 3 Warning 修复 (relay 测量中“未训练”语义污染；臂间选择性报告改为全臂披露 + bootstrap CI)。E-H 轮：**零缺陷**——首次干净审计，归因于实验前三视角评审在运行前捕获命名陷阱。这条轨迹本身就是协议自校正的证据。

新颖性复审。 实验后二次检索发现 GRESO 在事前零方差过滤上的优先权 (写作草稿漏检)；定位随即修正 (独立重发现；增量声明限于评分器消融、容量理论与 regime 判据)，教训制度化原则 (1)。

8 效度威胁

任务与硬件范围。 全部训练使用 GSM8K 规则数值奖励、单一 GPU 型号；容量阶梯常数与 μ_0 区间是数据集特定的。跨架构迁移 (§3.5、§5.8) 检验形式可移植性而非跨任务普适性；MATH/代码任务的不同通过率分布会移动 S_0 与 regime 边界。

Seed 与环境混淆。 500 步里程碑为单 seed；三 seed 500 步 run 跨度 40.4–45.6% (均值 43.3%, $\sigma=2.6$ pp)，且 seed 7/123 在重建的软件环境下运行，部分方差可能源于环境。所有用于判定的成对效应均超过相应轮次的 2σ (按预注册单 seed 条款)。

非确定性。 同 seed 同配置重跑在 ROCm 上分叉约 3 pp (反向原子操作)；全部对照因此同轮配对，重跑检查在记分卡中如实标注。

度量局限。 fzs 按构造把投资槽计为零信号 (机制性而非动力学偏离——F-f 已标注)；二值通过率近似低估格式分歧组的信号； τ_{net} 推导视池构成为 cycle 内准静态。

单 seed regime 点。 Pool-200/500 的 regime 判定各依单 seed，效应量 $\gg 2\times$ 实测 100 步 seed 噪声；预注册条款接受其仅作符号判定。

独立重发现。 ZSBR 骨架与 GRESO 重叠；我们声明的是 §2.2 所列增量，而非方向本身。

9 局限与未来工作

容量阶梯与封顶定理在 $G=2$ 下验证； $G=4$ 的闭式后验期望评分器已推导 ($L_1(G=4)=0.875$, $S_0(G=4)=0.212$ 实测) 但未端到端训练。耗竭 regime 本身在任何调度下均未被观测 (推论 3 说明带冷却时它不可能被观测)；无冷却长训练于极小池是否会进入耗竭、投资是否转正，仍然开放。图表生成应用方向经预注册闸门判定视觉转录任务不适定后降级为未来工作。由于自回归生成主导步时，rollout 内的无损推测解码是自然的第四层；对训练检查点上 drafter 接受率 $\alpha(t)$ 的首测显示分布特异性重分配而非单调衰减 (任务分布接受率随策略学会可复用模板而上升、held-out 下降)，提示推测 rollout 的收益须按 regime 建模，与动力学层的 τ_{net} 结构互为镜像。

10 结论

有效的 RLVR 可通过系统化的逐层优化在单张消费级 GPU 上实现。核心洞见是递进极限方法论本身：吃干每层天花板再下沉，我们得到了反直觉的结论——最简单的调度器 (带冷却的贪心) 在现实约束下最优——而这一结论需要容量理论、动力学模型与不可能性定理三者才能严格建立。对实践者：使用后验期望贪心选择约 500 道精选题，不要投资课程学习——补给主导 regime 下它纯属机会成本。

参考文献

- Zhaolin Gao, Joongwon Kim, Wen Sun, Thorsten Joachims, Sid Wang, Richard Yuanzhe Pang, and Liang Tan. Prompt curriculum learning for efficient llm post-training. *arXiv preprint arXiv:2510.01135*, 2025.
- Yu Huang et al. On the emergence of implicit curriculum in rlvr learning dynamics. *arXiv preprint arXiv:2602.14872*, 2026.
- Thanh-Long V. Le, Myeongho Jeon, Kim Vu, Viet Lai, and Eunho Yang. No prompt left behind: Exploiting zero-variance prompts in llm reinforcement learning via entropy-guided advantage shaping. *arXiv preprint arXiv:2509.21880*, 2025. ICLR 2026 camera-ready.
- Gengsheng Li, Tianyu Yang, Junfeng Fang, Mingyang Song, Mao Zheng, Haiyun Guo, Dan Zhang, Jinqiao Wang, and Tat-Seng Chua. Unifying group-relative and self-distillation policy optimization via sample routing. *arXiv preprint arXiv:2604.02288*, 2026.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- Qiyang Yu et al. Dapo: An open-source llm reinforcement learning system. *arXiv:2503.14476*, 2025.

Haizhong Zheng, Yang Zhou, Brian R. Bartoldson, Bhavya Kailkhura, and Beidi Chen. Act only when it pays: Efficient reinforcement learning for llm reasoning via selective rollouts. *arXiv preprint arXiv:2506.02177*, 2025.

A 完整预言记分卡

全部阈值在实验前写入时间戳。判定符号：✓ 确认、× 证伪、U 诚实条款下不可判定。

#	预言	实测	判定
F-a	fzs 回升 $\geq +3\text{pp}$	-3.4pp	U ($\tau \approx 2500 \gg 500$; 发现补给分支)
F-b	平台 RMSE $< 5\text{pp}$	5.2pp	× (边缘; μ_0 低估 4×)
F-c	sfc 信号 $\geq v1+5\%$	-17%	×
F-d	sfc held-out $\geq v1-1\text{pp}$	-6.4pp	× (净伤害, $z=2.05$)
F-e	转化校准 $R^2 \geq 0.7$	$R^2 < 0$ (高估 1.54×)	× (审计改判)
F-f	sfc $\approx v1$ 前 100 步	5.2pp	× (口径限制)
G-a	pool500 fzs 回升 $\geq +3\text{pp}$	-4.1pp	× (平衡分支)
G-b	sfc500 通量 $\geq +5\%$	-10.5%	× (McNemar $p < 0.001$)
G-c	n_{eff} 校准误差 $< 10\text{pp}$	17.1pp	× (选择性偏差; 随 n 消失)
H-a	pool200 fzs 回升 $\geq +3\text{pp}$	-0.5pp	× (轮转平衡)
H-b	sfc200 通量 $\geq +5\%$	+4.5%	× (边缘; 惰性化)
H-c	$v1(200)$ held-out $\geq 40\%$	37.4%	× (下限 $\in (200, 500]$)
H-d	平台 $\mu_0 \in [0.002, 0.008]$	0.0081	× (超 0.0001; 在 CI 内)
A1-a	nocool 回升 $\geq +3\text{pp}$	+4.09pp	✓ (净 -0.92 pp vs. 冷却)
A1-b	held-out 等价带	+0.6pp	✓ (等价)
A1-c	p200 平台破裂 $\geq 3\text{pp}$	-15pp	✓ (held-out +3.8 pp, 1 seed)
A3	3-seed 均值 $\in [43.5, 47.5]\%$	$43.3\% \pm 2.6$	× (边缘; 环境混淆)
A4	数据下限 $\in (300, 400]$	方向性	方向性观测 (跨轮)
C1	DGBB 形式迁移 $R^2 \geq 0.95$	0.9983	✓ (形式可迁移)
C2	ZSBR held-out 增益 > 0 (E2B)	-0.40pp	× (S_0 压缩; 4× 方差降)
C3-a	pool7473 平台 $< 10\text{pp}$	-2.8pp	✓ (补给平台)
C3-b	pool500 耗竭 $\geq 10\text{pp}$	-2.1pp	× (边界 < 500)

首轮: 1 不可判定 + 12 ×, 全部收敛于同一自洽图景; 每个 × 都产出有记录的理论修正。WS-A 后续轮: 5 项 3 确认 (平衡 regime 封顶成立; 池大小边界定位于 200), 1 项边缘受环境混淆, 1 项方向性。WS-C 轮: 4 项 2 确认可移植性; 两项 × 定位需按基座重测的模型特定参数。

B Run 清单

全部 run: RX 7900 XTX, gen128 (pdb4, ga32), $G=2$, 基座 Qwen2.5-3B-Instruct (另注除外); 评估 GSM8K test[:500], batch 32。工件 (config.json、timing.json、efficiency_report.json、reward_log.jsonl、逐题正确向量) 发布于仓库 results/ 目录。

Run	步数	池	关键数字
uniform s42/s7/s123	100	7473	held-out 31.0/33.2/34.0%
zsbr_v1 s42/s7/s123	100	7473	held-out 39.6/41.4/40.6%
zsbr_v1.0 点估计	100	7473	fzs 0.708 (消融失败)
zsbr_v2 s42	100	7473	held-out 40.2%, 重复槽 0
zsbr_v1_500 s42	500	7473	held-out 45.6% (228/500)
zsbr_sfc_500 s42	500	7473	held-out 39.2%, -6.4 pp
zsbr_v1_500_p500 s42	500	500	held-out 45.4% (15× 效率)
zsbr_sfc_500_p500 s42	500	500	held-out 38.8%, -6.6 pp
zsbr_v1_500_p200 s42	500	200	held-out 37.4%
zsbr_sfc_500_p200 s42	500	200	held-out 36.6%, 不显著
p200 cool/nocool 对	500	200	平台 -15 pp; held-out +3.8 pp
E2B uniform/zsbr	100	7473	29.27/28.87%, σ 1.2→0.3 pp
E2B zsbr p7473/p500	500	—	fzs 平台 -2.8/-2.1 pp
DGBB 2D 扫描 (9 点)	10	7473	拟合残差 $\leq 3.3\%$; 探针 (8,256)